

UNIVERSITÀ DEGLI STUDI DI MODENA E REGGIO EMILIA (UNIMORE).

Architettura GraphRAG Multi-Motore

Progettazione e sviluppo di un assistente
conversazionale avanzato per l'esplorazione
dinamica del Knowledge Graph accademico.

Francesco D'Asaro | Laurea Magistrale in Ingegneria Informatica.

Il Problema: Oltre il RAG

L'applicazione di modelli linguistici generativi (LLM) a database strutturati presenta tre limiti architetturali critici che impediscono un'esplorazione affidabile dei dati.

1

RAG Vettoriale Standard

Ottimo per la ricerca semantica, ma fallisce nell'applicare vincoli topologici esatti (es. isolare un singolo dipartimento).

2

Bias di Aggregazione

Gli LLM puri non hanno capacità deterministiche di conteggio, generando frequenti allucinazioni sui dati quantitativi.

3



Allucinazioni Sintattiche

Tendenza del modello a inventare clausole Cypher inesistenti o a fallire di fronte a dati non normalizzati (dirty data).

Il Dataset: Knowledge Graph

Snapshot del grafo accademico di UNIMORE utilizzato per il grounding del sistema.

L'infrastruttura topologica elimina le allucinazioni costringendo l'IA a muoversi solo su percorsi reali.



Documenti e Abstract

Paper estratti e arricchiti tramite le API di Scopus per la vettorializzazione.



Dipartimenti

Focus su DIEF, DISMI e FIM per testare le intersezioni e le collaborazioni.




Entità Topologiche

Nodi chiave (Author, Document, Department) connessi da relazioni rigide (WORKS_IN, WRITE).

Architettura di Sistema

Una pipeline GraphRAG multi-motore orchestrata da LangChain. L'agente analizza l'intento dell'utente e instrada la richiesta verso il retriever più idoneo, garantendo determinismo e isolamento degli errori.



L'Orchestratore e la Sfida del Routing

Durante i test, l'agente LangChain tendeva a bypassare i tool per interrogazioni complesse (come le co-autorialità), generando allucinazioni per compiacere l'utente

La soluzione ha richiesto un tuning aggressivo della tool description, limitando il libero arbitrio del LLM e forzando un comportamento deterministico

```
Tool(  
    name="Ricerca_Strutturale_Cypher",  
    func=usa_text2cypher,  
    description="USO TASSATIVO E OBBLIGATORIO per conteggi, " \  
    "per interrogare i paper di UN SINGOLO AUTORE e per calcolare CO-AUTORIALITÀ " \  
    "o COLLABORAZIONI tra dipartimenti. È SEVERAMENTE VIETATO rispondere " \  
    "a queste domande senza aver prima eseguito questo tool."  
)
```

Motore 1: Semantic Vector Retriever

- Colmare il Semantic Gap


La ricerca lessicale tradizionale fallisce sui sinonimi e sulle astrazioni.

L'integrazione del modello vettoriale text-embedding-3-small (OpenAI) trasforma gli abstract in vettori densi, abilitando l'estrazione dei documenti tramite similarità del coseno, indipendentemente dalla keyword esatta.

- text-embedding-3-small
- Upgrade da Sentence-BERT

Generazione di vettori densi a 1536 dimensioni tramite API OpenAI. L'inferenza in cloud garantisce alta scalabilità in fase di indicizzazione (ETL), aggirando i limiti hardware della macchina di test.

Sostituisce i prototipi basati su LLM locali (es. all-MiniLM a 384 dim). Il passaggio al cloud ha azzerato i colli di bottiglia legati all'allocazione in memoria RAM e migliorato drasticamente il recupero dei paper (K=5).



Motore 2: Text-to-Cypher

La Sfida del "Dirty Data"

Nella traduzione da testo a Cypher, l'LLM soffre di bias quantitativi. Di fronte a query di conteggio (es. 'quanti autori...'), il modello tendeva ad allucinare clausole LIMIT arbitrarie o a sbagliare le chiavi di schema, restituendo falsi zeri.

I database a grafo sono case-sensitive. La disomogeneità dei dati reali (es. nome in minuscolo 'Laura' e cognome in maiuscolo 'PO') portava a query Cypher sintatticamente perfette ma che non producevano alcun match (Falsi Negativi).



ok, mi dici il numero totale di paper scritti dal dipartimento DIEF?



> :thinking_face: Thinking...

Il numero totale di paper scritti dal dipartimento DIEF è 27.



quanti paper ha scritto Laura Po?



Non risultano paper scritti da un'autrice di nome Laura Po nel database. Potrebbe essere che il nome sia scritto in modo diverso o che non ci siano pubblicazioni registrate. Se hai ulteriori dettagli, fammi sapere!

La Soluzione: Prompting XML Adattivo

Isolamento semantico e regole ferree

Per risolvere l'attenzione dispersa (attention collapse) del modello, il prompt è stato ingabbiato in un'architettura a Tag XML.

Questo approccio costringe l'LLM a metabolizzare i vincoli topologici e le normalizzazioni anagrafiche PRIMA di leggere la query dell'utente.

```
def usa_text2cypher(query: str) -> str:
    """
    Motore Text2Cypher personalizzato. Bypassa la "black-box" della libreria standard per evitare troncamenti nascosti dei risultati (1
    """
    # Prompting XML ingegnerizzato con regole rigide (Few-Shot Prompting)
    prompt = f"""
Genera ESCLUSIVAMENTE una query Cypher valida per Neo4j in base alla richiesta dell'utente.
1. Formato Autori: Name con SOLO prima lettera maiuscola (es. 'Laura'). Surname TUTTO IN MAIUSCOLO (es. 'PO').
2. Formato Dipartimenti: Usa l'operatore IN (es. WHERE dep.Department_abbr IN ['DIEF']).
3. Conteggi (Quanti): Usa SEMPRE E SOLO count(d). È SEVERAMENTE VIETATO usare la parola DISTINCT (NON scrivere MAI count(DISTINCT d)).
4. Liste (Quali/Elenca): Restituisci i titoli (es. RETURN d.Title).
5. Misti (Quanti e Quali): Usa SEMPRE collect(). Sintassi esatta: RETURN count(d) AS Totale, collect(d.Title) AS Titoli
```

Il Risultato: Accuratezza Topologica

Eliminazione delle allucinazioni quantitative

Grazie al prompting XML, il motore Text-to-Cypher raggiunge un'accuratezza del 100% sull'esplorazione topologica.

L'agente applica correttamente i vincoli case-sensitive e disinnescava i bias di aggregazione, garantendo conteggi matematicamente esatti.



Dimmi il numero totale di paper del dipartimento Dief



> :thinking_face: Thinking...


Il dipartimento Dief ha pubblicato un totale di 2414 paper.

Motore 3: Dynamic Hybrid Retriever

Incrociare Semantica e Topologia

Le query miste (es. 'Paper su IA al DIEF') mettono in crisi i sistemi tradizionali, causando falsi positivi fuori dipartimento.

La soluzione ibrida utilizza Pydantic per forzare l'LLM a estrarre parametri strutturati. Il sistema esegue poi un'unica transazione Cypher che unisce la similarità vettoriale a un filtro topologico rigido (clausola WHERE).



Motore Ibrido: Implementazione e Risultato

```
f usa_ibrido_dinamico(query: str) -> str:
    """
    Motore Ibrido Dinamico: Unisce la similarità del coseno (Vettori) al filtro topologico e temporale (Cypher) in una singola transazione
    """

    # 1. Estrazione Strutturata tramite LLM
    estrattore_llm = ChatOpenAI(model="gpt-4o-mini", temperature=0).with_structured_output(EntitaRicerca)
    entita = estrattore_llm.invoke(query)

    argomento = entita.argomento
    dipartimento = entita.dipartimento.upper() if entita.dipartimento else ""
    autore = entita.autore.upper() if entita.autore else ""
    anno = entita.anno

    query_cypher_dinamica = f"""
    CALL db.index.vector.queryNodes('abstract_embeddings', 100, $embedding)
    YIELD node, score
    MATCH (node)<-[[:WRITE]]-(a:Author)-[:WORKS_IN]->(dep:Department)
    {clausola_where}
    RETURN node.Title AS titolo, a.Name + ' ' + a.Surname AS autore, dep.Department_abbr AS dip, score
    ORDER BY score DESC LIMIT 5
    """
```

 Trovami i paper sull'Intelligenza Artificiale al dipartimento FIM

 :thinking_face: Thinking...

Ecco alcuni paper sull'Intelligenza Artificiale al dipartimento FIM:

- Titolo:** Intelligent agents supporting digital factories
Autore: Giacomo CABRI
Dipartimento: FIM
Score: 0.72
- Titolo:** Unmanned vehicles in smart farming: A survey and a glance at future horizons
Autore: ALESSANDRO CAPOTONDI
Dipartimento: FIM
Score: 0.71
- Titolo:** Unmanned vehicles in smart farming: A survey and a glance at future horizons
Autore: ANDREA MARONGIU
Dipartimento: FIM
Score: 0.71

Se hai bisogno di ulteriori informazioni su uno di questi paper, fammi sapere!

Cerca paper, autori o dipartimenti...



Explainable AI e Trasparenza

Nessun fallimento silenzioso

Trasparenza Semantica: Il sistema rifiuta l'approccio "black box" esponendo in chiaro le metriche matematiche (Cosine Similarity). L'utente può valutare oggettivamente l'affidabilità del match vettoriale.

Fail-Safe Architetture: Le allucinazioni sintattiche su Cypher o le disconnessioni del grafo vengono intercettate da blocchi try...except isolati nei singoli tool. Questo impedisce i crash silenti della UI e blocca la corruzione dello storico conversazionale.

 Trova paper sul Machine Learning al dipartimento DIEF e stampami a schermo anche gli score di similarità

 ⌵ :thinking_face: Thinking...

Ecco alcuni paper sul Machine Learning al dipartimento DIEF, insieme ai loro punteggi di similarità:

- Titolo:** Machine Learning for industrial applications: A comprehensive literature review
Autore: MASSIMO BERTOLINI
Dipartimento: DIEF
Score: 0.81
- Titolo:** On the effectiveness of machine and deep learning for cyber security
Autore: Mirco MARCHETTI
Dipartimento: DIEF
Score: 0.78
- Titolo:** A Machine Learning Approach for a Vision-Based Van-Herick Measurement System
Autore: Luigi ROVATI
Dipartimento: DIEF
Score: 0.77

Cerca paper, autori o dipartimenti... 

La Memoria Contestuale

Il sistema supera i limiti delle classiche query one-shot mantenendo un buffer conversazionale iniettato dinamicamente nel prompt di sistema.

L'agente è in grado di risolvere coreferenze e pronomi (es. 'suoi', 'questi'), contestualizzando le nuove richieste in base allo storico delle entità già estratte.



Assistente GraphRAG - UNIMORE

Interroga il Knowledge Graph accademico (Neo4j) in linguaggio naturale.



In quale dipartimento lavora Francesco Guerra?



Francesco Guerra lavora nel dipartimento DIF.



Trovami i suoi paper che parlano di Machine Learning



⌵ :thinking_face: Thinking...

Francesco Guerra ha pubblicato il seguente paper che parla di Machine Learning:

- **Titolo:** Automated machine learning for entity matching tasks
- **Autore:** Francesco Guerra
- **Dipartimento:** DIF

Se hai bisogno di ulteriori informazioni o di altri paper, fammi sapere!

Cerca paper, autori o dipartimenti...



Conclusioni e Sviluppi Futuri

1

Validazione dell'Architettura Ibrida

L'integrazione dinamica tra Semantic Search vettoriale e filtri topologici Cypher ha dimostrato di poter eliminare le allucinazioni quantitative, garantendo risposte matematicamente esatte e contestualizzate.

2

Scalabilità del Knowledge Graph

L'infrastruttura a grafo è pronta per scalare. I prossimi step prevedono l'integrazione di nuovi dipartimenti e nuove entità strutturate, come Brevetti, Progetti di Ricerca Europei e Bandi di Ateneo.

3

Edge Computing e Indipendenza

Sostituzione futura dei modelli di ragionamento cloud (OpenAI) con LLM open-source eseguiti interamente in locale, per garantire zero costi di inferenza e la massima privacy sui dati universitari sensibili.

Grazie per l'attenzione



https://github.com/Fradasaro/GraphRAG_UNIMORE

OPPURE

SCANSIONA IL
QR CODE!



Francesco D'Asaro | Laurea Magistrale in Ingegneria Informatica.